

YOLO Tabanlı İnsan ve Baret (Kask) Tespit Sistemi

Proje Geliştirme Raporu

Tarih: 28 Temmuz 2026

1. Yönetici Özeti

Bu rapor, iş güvenliği amacıyla kamera görüntüsü üzerinden insan ve baret (güvenlik kaskı) tespiti yapan bir Object Detection sisteminin geliştirme sürecini özetlemektedir. Sistem, Ultralytics YOLO11n mimarisi kullanılarak sıfırdan bir dataset üzerinde eğitilmiştir. Proje, doğrudan asıl hedef olan saha (elektrik direği) senaryosuna geçmeden önce, veri bulma ve etiketleme süreçlerinin daha kolay olduğu insan + baret problemi üzerinden uçtan uca bir Object Detection geliştirme deneyimi kazanmak amacıyla planlanmıştır.

Üç dataset ve eğitim iterasyonu sonucunda, mevcut model insan ve baret ayrımını genel olarak başarılı şekilde yapabilmektedir ($mAP50 \approx 0,87$). Ancak baretin sağlam mı yoksa kırık/hasarlı mı olduğu ayrımı, eğitim verisinde bu duruma ait yeterli örnek bulunmadığı için henüz güvenilir şekilde yapılamamaktadır. Bu husus, projenin bir sonraki aşaması için ana geliştirme alanı olarak belirlenmiştir.

2. Projenin Amacı ve Kapsamı

Projenin nihai hedefi, elektrik direklerinde gerçek zamanlı yuva tespiti yapabilen bir Object Detection sistemi geliştirmektir. Ancak bu problem için hazır ve yeterli veri bulunmadığından, önce veri temini ve etiketlemenin daha kolay olduğu bir problemle YOLO tabanlı bir projenin baştan sona nasıl geliştirildiğinin öğrenilmesine karar verilmiştir. Bu amaçla insan ve güvenlik baretinin tespiti hedeflenmiştir.

Sistemin planlanan temel işlevi:

- Görüntü veya kamera akışında insanları tespit etmek
- Baret (helmet) takıp takmadıklarını tespit etmek
- İleri aşamada baretin sağlam mı yoksa kırık/hasarlı mı olduğunu ayırt etmek
- Tüm bu tespitleri gerçek zamanlı olarak (webcam / video akışı üzerinde) çalıştırmak

Bu kapsam, proje ilerledikçe deneyim ve gözlemler doğrultusunda güncellenmiştir; bu güncellemeler Bölüm 4 ve 5'te ayrıntılı olarak açıklanmaktadır.

3. Kullanılan Yöntem ve Araçlar

3.1 YOLO (You Only Look Once)

YOLO, bir görüntüyü tek bir ileri geçişte analiz ederek içindeki nesnelerin sınıfını ve konumunu (bounding box) aynı anda tahmin eden bir Object Detection (nesne tespiti) mimarisidir. Bu proje kapsamında YOLO11 ailesinin en hafif versiyonu olan YOLO11n (Nano) tercih edilmiştir.

YOLO11n seçilme gerekçeleri:

- Hafif ve hızlı bir model olması
- CPU üzerinde de makul sürede çalışabilmesi
- Gerçek zamanlı uygulamalara uygun olması

- Amacın en yüksek doğruluğu değil, önce uçtan uca pipeline'ı sağlıklı şekilde kurup öğrenmek olması

3.2 Kullanılan Araçlar

Araç / Kütüphane	Kullanım Amacı
Python	Projenin geliştirildiği dil
Ultralytics (YOLO)	Model yükleme, eğitim (train) ve tahmin (inference)
Roboflow	Görüntülerin etiketlenmesi (annotation) ve YOLO formatında dataset export
OpenCV (cv2)	Görüntü okuma/gösterme, nesne kırpmaya (crop), gerçek zamanlı kamera akışı

4. Geliştirme Süreci

4.1 Hazır Model ile İlk Deneme

Sıfırdan model eğitmeden önce, COCO veri setiyle önceden eğitilmiş hazır bir YOLO11n modeli (yolo11n.pt) kullanılarak Object Detection mantığı öğrenilmiştir. Bu aşamada modelin döndürdüğü sonuç yapısı (results) incelenmiş; boxes, orig_img, xyxy koordinatları, class id ve confidence değeri gibi kavramlar öğrenilmiştir. Ayrıca bounding box koordinatları kullanılarak tespit edilen nesnenin görüntüden kırılabilceği (crop) görülmüştür (bkz. Bölüm 6.1).

Bu aşamada karşılaşılan önemli bir öğrenme noktası, bir görüntüde birden fazla nesne olduğunda tüm tespitlerin bir döngü ile tek tek işlenmesi gerektiğidir; başlangıçta yalnızca ilk tespit alınırken, ilerleyen aşamada tüm tespitlerin ayrı ayrı değerlendirilmesi gerektiği fark edilmiştir.

4.2 Dataset Oluşturma ve Etiketleme

Kendi modelini eğitebilmek için görüntü + etiket (label) çiftlerinden oluşan bir dataset gerektiği öğrenilmiş ve etiketleme süreci için Roboflow platformu kullanılmıştır. Etiketleme hem manuel (elle kutu çizerek) hem de Roboflow'un otomatik öneri özelliğiyle yapılmış, otomatik önerilen etiketler kontrol edilerek düzeltilmiştir.

YOLO etiket formatı, her görüntü için bir .txt dosyasında şu şekilde tutulmaktadır:

```
class_id  x_center  y_center  width  height
0         0.5    0.4      0.2    0.3
```

Koordinatlar görüntü boyutundan bağımsız olacak şekilde 0-1 arasında normalize edilmiştir. Dataset; model eğitiminde kullanılan train, eğitim sırasında performansı izlemek için kullanılan valid ve modelin daha önce görmediği verilerle nihai değerlendirmesinin yapıldığı test olmak üzere üç bölüme ayrılmıştır.

4.3 İlk Model Eğitimi

İlk aşamada yaklaşık 20 görüntülük küçük bir dataset ile People (insan) ve Helmet (baret) olmak üzere iki sınıflı bir model eğitilmiştir. Eğitim parametreleri: YOLO11n, imgsz=640, epochs=50, batch=4. Bu ilk modelin amacı yüksek doğruluk elde etmek değil, eğitim-doğrulama sürecinin ve dataset formatının doğru kurulup kurulmadığını doğrulamaktır. Sonuçlar (mAP50 ≈ 0,57) bu amaç için yeterli görülmüş, ancak modelin gerçek kullanım için geliştirilmesi gerektiği netleşmiştir.

4.4 Model İyileştirme Süreci

Test ve gerçek zamanlı kamera denemelerinde modelin bazı insanları birleştirerek tek nesne olarak algıladığı ve zaman zaman saç/kafa bölgesini baret ile karıştırdığı gözlemlenmiştir. Bu durumun temel nedeni, eğitim setinde baretsiz insan örneklerinin az olması olarak değerlendirilmiştir — model, kendisine gösterilen görüntüleri öğrenir; baretsiz insan yeterince gösterilmediğinde bu durumu ayırt etmeyi öğrenemez.

Bu gözlem doğrultusunda dataset genişletilmiş, baretli ve baretsiz insan görüntüleri daha dengeli biçimde eklenmiş ve veri çeşitliliğini artırmak amacıyla data augmentation (döndürme, çevirme, kırpma, parlaklık/kontrast değişimi vb.) uygulanmıştır. Augmentation'ın yeni gerçek veri üretmediği, mevcut verilerden varyasyon ürettiği bilinerek kullanılmıştır.

4.5 Kırık Baret Problemi ve Mimari Değerlendirme

Saha senaryosunda baretin sadece var olup olmadığının değil, sağlam mı yoksa kırık/hasarlı mı olduğunun da tespit edilmesi gerektiği ortaya çıkmıştır. İlk planlanan mimari, ikinci bir modelin (Model 2) yalnızca kırılmış baret görüntülerini inceleyerek kırık/sağlam ayrımı yapması şeklindeydi:

Model 1 (People + Helmet) -> Helmet crop -> Model 2 (Broken Helmet)

Ancak Model 2'yi geliştirmeye başlamadan önce, mevcut Model 1'in kırık baretli görüntülerde bazı durumlarda tek bir bareti iki ayrı nesne olarak algıladığı görülmüştür. Bu durum, Model 2 oluşturmadan önce Model 1'in dataset'inin kırık baret örneklerini de içerecek şekilde genişletilmesi gerektiğini göstermiştir; bu nedenle iki modelli mimari şimdilik ertelenmiş, tek model üzerinde dataset kalitesinin artırılmasına odaklanılmıştır.

4.6 Son Model Eğitimi

Son aşamada dataset yaklaşık 266 ham görüntüden, augmentation sonrası yaklaşık 750 görüntü/örneğe genişletilmiştir. Bu dataset'e baretli insanlar, baretsiz insanlar ve kırık/hasarlı baret örnekleri dahil edilmiştir. Model, önceki iterasyonun ağırlıklarından (train-3) devam edilerek yeniden eğitilmiştir (train-5), aynı temel parametrelerle: imgsz=640, epochs=50, batch=4.

5. Karşılaşılan Problemler ve Çözümler

#	Problem	Çözüm / Yaklaşım
1	YOLO çıktı yapısının (results, boxes, orig_img, xyxy) anlaşılabilmesi	Model çıktıları tek tek incelenmiş, bounding box koordinatlarıyla nesne kırpma denenerek yapı öğrenilmiştir
2	Görüntüdeki birden fazla nesnenin ayrı ayrı işlenememesi	Tüm tespitlerin bir döngü ile tek tek gezilmesi gerektiği anlaşılmıştır
3	Küçük dataset nedeniyle düşük doğrulama skorları	Dataset büyütülmüş ve çeşitlendirilmiştir
4	Baretsiz kişilerin baretli olarak algılanması (saç/kafa karışıklığı)	Baretsiz insan örnekleri dataset'e dengeli biçimde eklenmiştir
5	Kırık baretlerin iki ayrı nesne olarak algılanması	Kırık baret örnekleri Model 1 dataset'ine dahil edilmiş, iki modelli mimari ertelenmiştir
6	Kırık/sağlam baret ayrımının halen güvenilir olmaması	Yetersiz veri; ek veri toplama ihtiyacı Bölüm 8'de ele alınmıştır

6. Model Sonuçları Karşılaştırması

Proje boyunca üç ana model iterasyonu değerlendirilmiştir. Aşağıdaki tablo, dataset büyüklüğü ve doğrulama (validation) sonuçlarının gelişimini özetlemektedir.

Model	Val. Görüntü	Val. Instance	Precision	Recall	mAP50	mAP50
İlk Model	4	30	0,636	0,536	0,569	0,34
Geliştirilmiş Model	10	58	0,916	0,879	0,941	0,64
Son Model	23	125	0,892	0,809	0,868	0,56

Not: Son modelin doğrulama seti önceki iterasyona göre büyümüş (58 → 125 örnek) ve daha çeşitli, daha zor senaryolar (farklı açılar, kısmi görünürlük, kırık baret örnekleri) içerecek şekilde genişlemiştir. mAP50 değerindeki hafif gerileme (0,941 → 0,868), modelin kötüleşmesinden değil, ölçümün artık daha büyük ve daha gerçekçi bir örneklemi yansıttığından kaynaklanmaktadır.

6.1 Son Model — Sınıf Bazında Sonuçlar

Sınıf	Görüntü	Instance	Precision	Recall	mAP50	mAP50
İnsan (class 0)	22	76	0,850	0,737	0,839	0,50
Baret (class 1)	16	49	0,935	0,882	0,896	0,62

6.2 Metriklerin Anlamı

- Precision: Modelin "bu bir baret" dediği tahminlerin ne kadarının gerçekten doğru olduğu
- Recall: Görüntüde gerçekten var olan nesnelerin ne kadarının model tarafından yakalanabildiği
- mAP50: IoU eşiği 0,5 alınarak hesaplanan, konum ve sınıf doğruluğunu birlikte özetleyen ana başarı metriği
- mAP50-95: Daha katı bir metrik; IoU eşiği 0,5'ten 0,95'e kadar farklı seviyelerde ortalama alınarak hesaplanır

7. Mevcut Durum ve Sınırlamalar

Çalışan: Sistem, kamera görüntüsü üzerinde insan ve baret (var/yok) ayrımını genel olarak başarılı şekilde yapabilmektedir (genel mAP50 ≈ 0,87). Gerçek zamanlı (webcam) üzerinde de bu tespit çalışır durumdadır.

Sınırlama: Baretin sağlam mı yoksa kırık/hasarlı mı olduğu ayrımı henüz güvenilir şekilde yapılamamaktadır. Bunun temel nedeni, mevcut modelin sınıflarının halen İnsan ve Baret ile sınırlı olması ve kırık baret örneklerinin dataset içinde yeterli sayı ve çeşitlilikte temsil edilmemesidir. Dataset'e kırık baret örnekleri eklenmiş olsa da, bu örneklerin sayısı güvenilir bir ayrım öğrenmesi için henüz yeterli görünmemektedir.

8. Kod Örnekleri

Aşağıda projenin farklı aşamalarında kullanılan üç temel kod bloğu yer almaktadır.

8.1 Hazır Model ile Tespit ve Nesne Kırpma (İlk Deneme Aşaması)

```
import cv2
from ultralytics import YOLO

model = YOLO("yolo11n.pt")
```

```


results = model("C:\\Users\\mehdi\\...\\image.jpg")
result = results[0]

image = result.orig_img # piksel dizisi

for i, class_id in enumerate(result.boxes.cls):
    if int(class_id) == 16:
        x1, y1, x2, y2 = result.boxes.xyxy[i].int().tolist()
        dog = image[y1:y2, x1:x2]
        cv2.imshow(f"Dogs {i}", dog)

cv2.waitKey(0)
cv2.destroyAllWindows()

```



Şekil 1: Hazır model ile insan/köpek tespiti ve nesne kırpma çıktısı — ilk deneme aşaması.

8.2 Custom Dataset ile Model Eğitimi

Önceki iterasyonun (train-3) ağırlıklarından devam edilerek, genişletilmiş son dataset üzerinde yeniden eğitim yapılmıştır:

```

from ultralytics import YOLO

# Önceki eğitimden (train-3) devam edilerek son dataset üzerinde eğitim
model = YOLO("runs/detect/train-3/weights/best.pt")

results = model.train(
    data="DatasetSon/data.yaml",
    epochs=50,
    imgsz=640,
    batch=4
)

```

8.3 Eğitilmiş Modelle Test Görüntüsü Üzerinde Tahmin


```

from ultralytics import YOLO

model = YOLO("runs/detect/train-5/weights/best.pt")

```

```
# Confidence değeri 0.25'in altında olan detection'lar gösterilmez
results = model("datasetSon/test/images/image1.jpg")
results[0].show()
```



Şekil 2: Son model (train-5) test görüntüleri üzerinde çalışırken — insan ve baret sınıfları tespit edilmiş durumda.

9. Sonraki Adımlar ve Öneriler

- Kırık/hasarlı baret için ek görüntü toplanması ve etiketlenmesi — mevcut sınırlamanın temel çözümü budur
- Sınıf dağılımının dengelenmesi (sağlam baret, kırık baret ve baretsiz insan örneklerinin dengeli oranlarda bulunması)
- Yeterli kırık baret verisi toplandıktan sonra, ayrı bir Model 2 (Broken Helmet) mimarisinin yeniden değerlendirilmesi
- Daha büyük model varyantlarıyla (ör. YOLO11s) doğruluk/hız karşılaştırması yapılması
- Gerçek saha koşullarında (farklı ışık, mesafe, açı) test edilerek modelin genelleme başarısının değerlendirilmesi
- İnsan + baret probleminde edinilen deneyimin, asıl hedef olan elektrik direklerinde yuva tespiti projesine aktarılması

10. Sonuç

Bu proje kapsamında yalnızca bir YOLO modeli eğitilmemiş, aynı zamanda bir Object Detection projesinin veri toplama, etiketleme, model eğitimi, doğrulama, hata analizi ve iyileştirme adımlarını içeren uçtan uca geliştirme süreci deneyimlenmiştir. Mevcut model insan ve baret ayrımını başarılı şekilde yapabilmektedir; kırık baret ayrımı ise bir sonraki geliştirme aşamasının odağıdır. Bu süreçte edinilen bilgi ve deneyim, projenin asıl hedefi olan elektrik direklerinde yuva tespiti çalışmasına doğrudan temel oluşturacaktır.